SD234401

Pembelajaran Mesin dengan Kesadaran Privasi
Privacy-Aware Machine Learning

Privasi Data dan Keamanan
Semester Genap 2025/2026

Neni Alya Firdausanti, S.Si., M.Stat., Ph.D
Muhammad 'Arif Faizin, S.Kom., M.Kom.

Target Pemahaman Materi

CPMK-1	Mampu memahami definisi teknis mengenai privasi dan keamanan data
CPMK-2	**Memahami konsep keamanan informasi, baik yang terdapat pada suatu komputer maupun yang sedang ditransmisikan pada suatu jaringan**
CPMK-3	**Mengaplikasikan teknik keamanan informasi baik secara mandiri maupun berkelompok**
CPMK-4	**Merancang teknik dan infrastruktur jaringan yang aman**

Kenapa Privasi itu Penting di *Machine Learning*?

Pertanyaan Utama:

Apakah mungkin kita menjawab pertanyaan menggunakan data yang tidak bisa kita lihat?

Kenapa Privasi itu Penting di *Machine Learning*?

Pertanyaan:

Bagaimana perbedaan antara orang yang terkena kanker paru-paru dan tidak menggunakan gambar tersebut?

Kenapa Privasi itu Penting di *Machine Learning*?

Pertanyaan:

Bagaimana perbedaan antara orang yang terkena kanker paru-paru dan tidak menggunakan data gambar tersebut?

Langkah -3: Cari partner bisnis

Langkah -2: Buat rencana bisnis

Langkah -1: Kumpulkan dana dan investor

Langkah 0: Beli dataset dari rumah sakit

Langkah 1: Kumpulkan jutaan contoh gambar kanker paru-paru

Kenapa Privasi itu Penting di *Machine Learning*?

Pertanyaan:

Bagaimana perbedaan antara angka tulisan tangan menggunakan gambar tersebut?

Kenapa Privasi itu Penting di *Machine Learning*?

Pertanyaan:

Bagaimana perbedaan antara angka tulisan tangan menggunakan gambar tersebut?

Langkah 1: Download dataset

Langkah 2: Download model State-of–the-Art (SotA)

Langkah 3: Jalankan model

Kenapa Privasi itu Penting di *Machine Learning*?

Kita BISA menyelesaikan permasalahan yang dapat diakses

- ImageNet
- MNIST
- CIFAR-10
- MS-COCO

Tapi bagaimana jika permasalahannya tentang:

- Kanker
- Alzheimer
- Demensia
- Depresi

Karena mendapatkan akses data privat itu SUSAH!

Kenapa Privasi itu Penting di *Machine Learning*?

Pada tahun 2006, Netflix mengumumkan **kompetisi $1 miliar dolar** untuk meningkatkan akurasi movie matching mereka dengan mempublish **dataset berisi rating dan tanggal saja**.

Namun beberapa minggu setelahnya, **Arvind Narayanan dan supervisornya Vitaly Shmatikov** berhasil menghubungkan ID unik dalam dataset tersebut kepada pengguna asli **menggunakan dataset IMDb**, lengkap dengan **informasi pribadi penggunanya.**

Kenapa Bisa Terjadi?

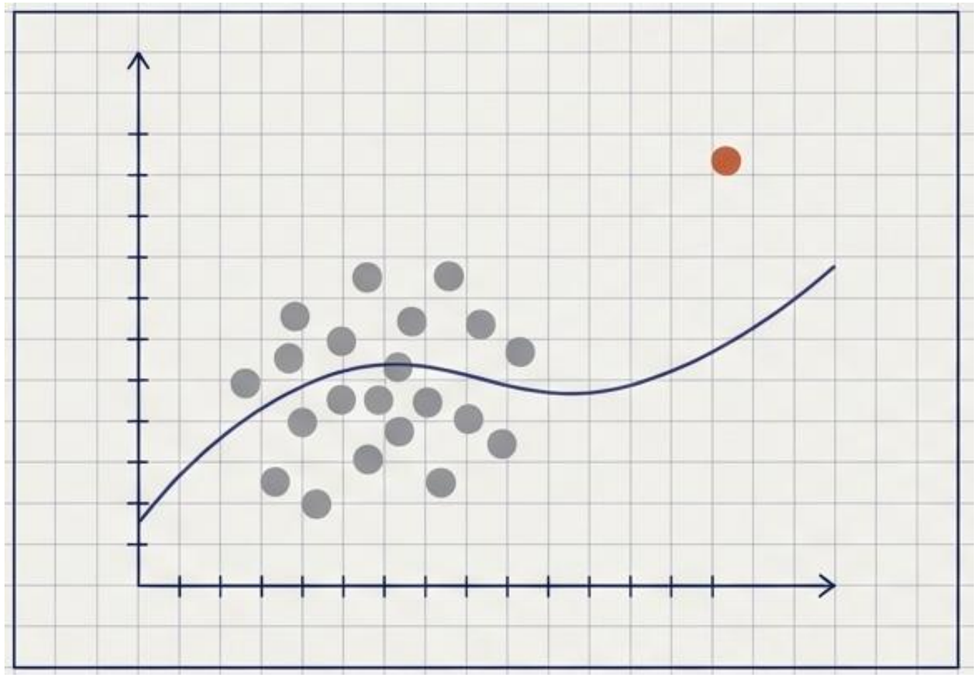

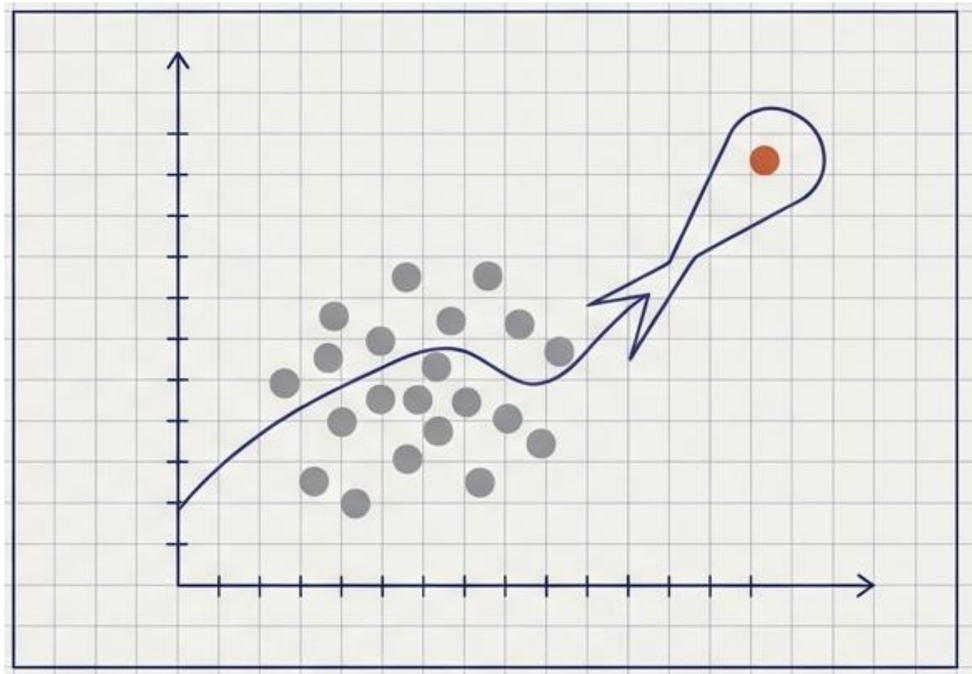

Asumsi umum: regularisasi dan generalisasi dapat menghilangkan resiko privasi dengan tidak mengekspos informasi pribadi

Realita: Seiring perkembangan ukuran dan parameter, model menyimpan informasi pribadi dari individu, bahkan termasuk dengan outlier

Privacy-Aware ML Workflow

Sehingga, diperlukan beberapa tahapan pengamanan privasi dalam setiap tahapan *machine learning*

Exploratory Data Analysis (EDA)

- Paradoks "Catch-22"
- Perlu memahami data sebelum memutuskan metode proteksi privasi
- Sementara butuh melihat data sebelum memahaminya

Feature Engineering

- Mengaplikasikan *pseudonymization* pada data
- Mengaplikasikan generalisasi menggunakan variabel

Training Model

- Menggunakan data partisi (PATE framework)
- Menambahkan *noise* pada *training* (DP-SGD)

Evaluasi dan *Governance*

- Memastikan *fairness*
- Mendokumentasikan melalui *Privacy Cards*

Privacy-Preserve Machine Learning bukan disiplin tersendiri,

tapi ***upgrade*** untuk sistem *Machine Learning* yang **sudah ada**

Catch-22 Problem

Butuh memahami data untuk tahu metode proteksi terbaik

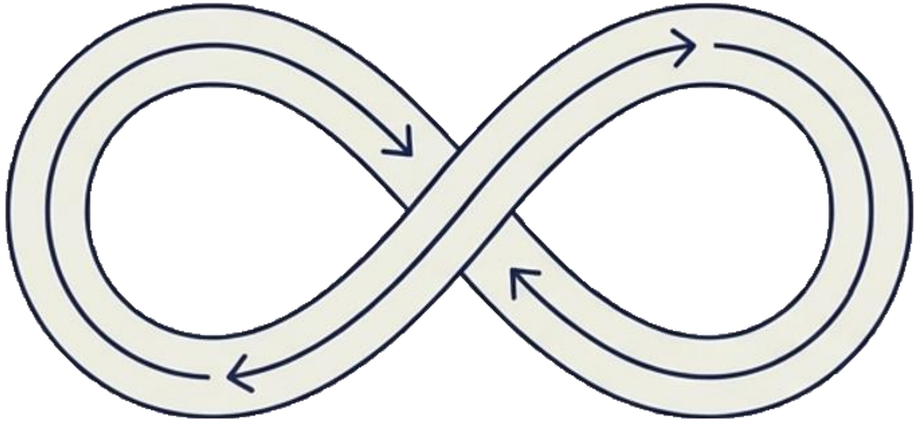

Butuh melihat data sebelum memahaminya

Catch-22 Paradox

Solusi Terorganisir

1. Pembatasan Data

Beri akses subset dari keseluruhan data kepada data analis untuk menganalisis karakter dari dataset

2. Setting Parameter

Tim menentukan batas, epsilon (ε), dan distribusi noise

3. Rilis Lebih Luas

Menggunakan mekanisme *differential privacy* dengan parameter yang ditentukan sebelumnya untuk dipublikasikan lebih luas

Mekanisme Privasi berdasarkan Tipe Data pada *Exploratory Data Analysis* (EDA)

Tipe Data	Mekanisme yang Mungkin	Contoh EDA
[#] Integer	Perturbation, bounding, differential privacy	Menggunakan differential privacy untuk mengakses data
[.00] Float	Rounding, perturbation, bounding, differential privacy	Membulatkan (rounding) dan bounding semua float ke atas atau ke bawah
[“abc”] String	Redaction, format-preserving encryption, cipher atau hashing, masking	Menggunakan library untuk mengenkripsi seluruh string atau mencari informasi potensial
[[v]] Vector	Differential privacy, perturbation	Menggunakan Gaussian differential privacy

Mekanisme Privasi pada *Feature Engineering*

Apakah fitur personal atau sangat sensitif?

Opsi A (*Redaction*): Bisakah fitur tersebut dihapus?

(Catatan: Teknik *statistical learning* masih dapat memprediksi berdasarkan *behaviour* tertentu)

Opsi B (*Pseudonymization*): Gunakan *masking*, *bounding*, atau *format-preserving encryption*
Contoh: tanggal lahir 31/12/1993 → 1990an

Opsi C (*Proxy Transformation*): Bisakah digantikan dengan fitur serupa?

The Proxy Problem

Studi Kasus	Prediksi kelayakan kredit, apakah seseorang layak untuk melunasi utang secara tepat waktu
Skenario	Kode Pos memiliki korelasi yang sangat kuat dengan ras dan status sosio-ekonomis
Aksi	Memetakan kode pos menjadi “Rata-rata penghasilan daerah”
Hasil	Generalisasi data, melindungi privasi, membuat model lebih objektif dalam menentukan prediksi

PATE *Framework*

(Private Aggregation of Teacher Ensembles)

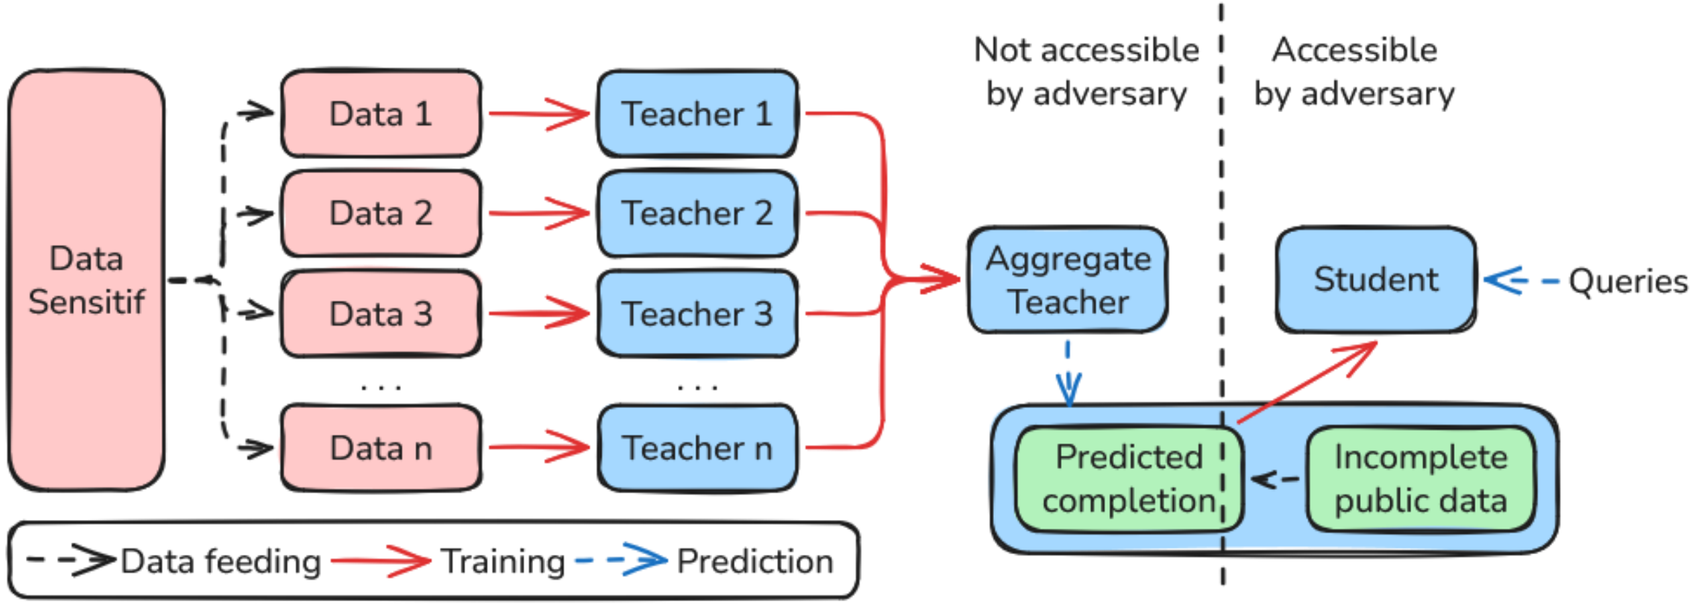

Mekanisme PATE memungkinkan privasi dari data sensitif tetap terjaga dengan melakukan **distilasi model Aggregate Teacher.**

Selain itu, penambahan ***Laplacian noise*** dengan sensitivity = 1 pada Aggregate Teacher dapat **menjamin differential privacy** tetap terjaga.

DP-SGD

(Differentially-Private Stochastic Gradient Descent)

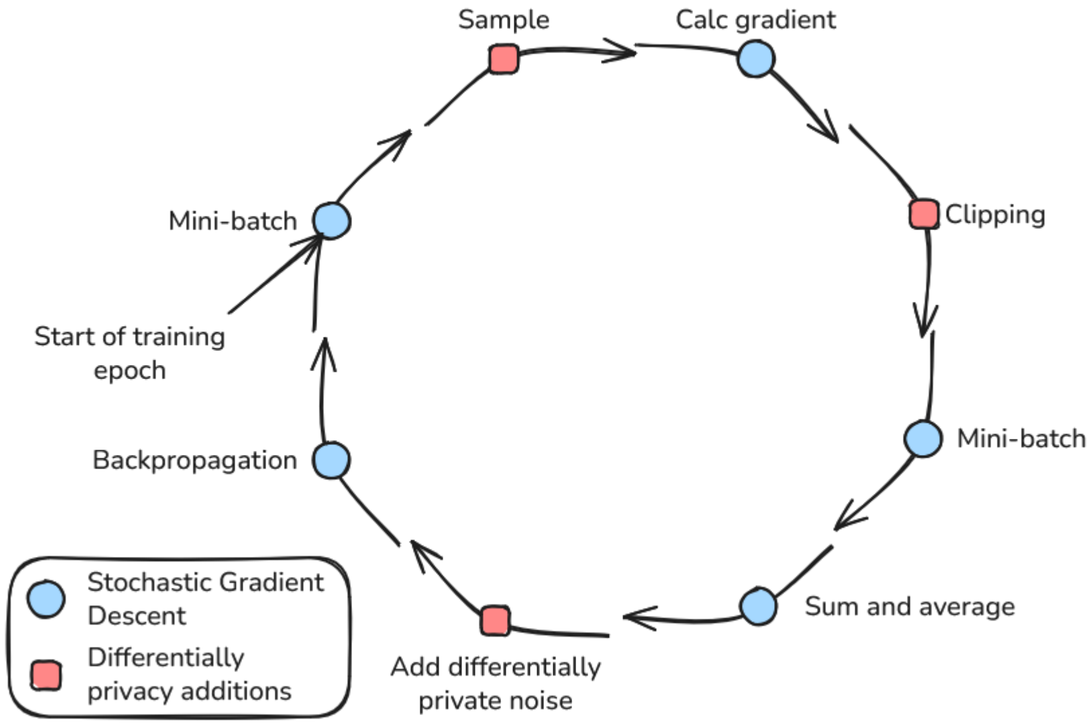

Untuk memastikan **informasi sensitif tetap terjaga** pada proses training model, DP-SGD menambahkan noise pada beberapa tahap:

1. **Per-sample** Gradient Calculation
2. Gradient **Clipping**
3. Noise **Addition**
4. **Privacy Budget Tracking**

Implementasi *Privacy Budget* (ε)

```
privacy_engine = PrivacyEngine()
model, optimizer, train_dataloader =
privacy_engine.make_private_with_epsilon(
    module=model,
    optimizer=optimizer,
    data_loader=train_dataloader,
    target_delta=DELTA,
    target_epsilon=EPSILON,
    epochs=EPOCHS,
    max_grad_norm=MAX_GRAD_NORM)
```

```
Epoch: 1 | Step: 1500 | Train loss: 1.928 | ... | Eval accuracy: 0.698 | ε: 3.68
Epoch: 1 | Step: 2000 | Train loss: 1.834 | ... | Eval accuracy: 0.720 | ε: 3.94
Epoch: 1 | Step: 2500 | Train loss: 1.711 | ... | Eval accuracy: 0.785 | ε: 4.14
```

Tools Differential Privacy

Open-Source: Opacus

Tracking Budget

Opacus dapat men*tracking* gradien pada setiap sampel selama *training* dan memberikan informasi privacy loss pada setiap step (ε dan δ).

Cost of Learning

Penggunaan *learning rate* lebih kecil membuat jumlah step lebih banyak, mempercepat peningkatan privacy budget

Mekanisme Privasi pada *Training Model*

	PATE Framework	DP-SGD
Mekanisme	Mengagregat **hasil vote** dari ***n teacher* model** yang telah dilatih terpisah dengan tambahan ***Laplacian noise***	Melakukan ***gradient clipping*** dan penambahan ***Gaussian noise*** pada *training*, terutama pada ***backpropagation***
Use Case Ideal	Algoritma apapun (**model agnostik**). Skenario dengan *student model* yang di*training* dengan **data publik yang besar**	Digunakan untuk ***fine-tuning*** **model *pre-trained*** yang telah tersedia secara umum.
Drawback	Membutuhkan **dataset yang masif** untuk dapat membuat **N *teacher model*** berbeda **tanpa irisan sama sekali**	Perlu memperhatikan ***privacy budget*** (ε) pada setiap ***epoch*** **selama *training***.

Algorithmic Anonymization (Privacy)

- **Fokus:** *Differential Privacy* (DP-SGC, PATE) → *Individual Privacy*
- **Tujuan:** Memastikan model tidak mengingat John Doe ada di dataset training
- **Kelemahan:** Model masih bisa belajar secara umum tentang ciri-ciri John Doe

Mathematical Privacy ≠ Societal Safety

Representational Transformation (Safety)

- **Fokus:** Keadilan melalui kesadaran → *Social Group Safety*
- **Tujuan:** Memastikan model tidak merugikan grup sosial tertentu
- **Insight:** *Privacy-Aware* ML tidak hanya menyelesaikan pada *row-level,* namun juga strategi mitigasi struktural

Fairness Through Awareness

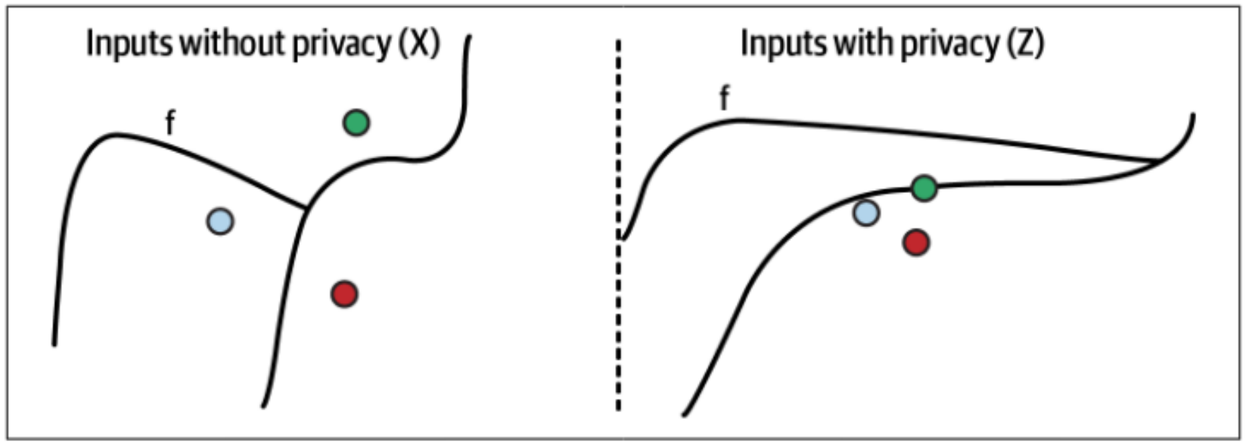

Representasi individu dengan fitur yang **hampir sama** dalam berbagai aspek, namun **berbeda pada atribut yang privat** (seperti gender atau ras) sehingga membuat representasi antar individu tersebut **berbeda**, maka terdapat kemungkinan untuk **menghasilkan transformasi** yang membuat representasi antar individu tersebut **menjadi lebih dekat** dengan **menghilangkan atribut privat**.

Studi Kasus: *Applicant Tracking System*

Problem: Joni adalah seorang yang memiliki etos kerja sangat baik, namun dia memiliki reputasi Universitas yang cukup jelek di mata perusahaan**.** Joni kesulitan mendapatkan pekerjaan akibat reputasi tersebut. Sebagai *Data Privacy Engineer*, bagaimana cara menerapkan *privacy-aware machine learning* pada data tersebut?

Algorithmic Anonymization (Privacy)

- **Aksi:** mengencode data raw nama "Asal Universitas" menjadi angka random untuk menyamarkan nama
- **Risiko:** pola universitas masih terlihat, perbedaan antar kampus tidak berubah

Proxy Transformation (Safety)

- **Aksi:** mengubah kolom "Asal Universitas" menjadi "Akreditasi Program Studi dan Universitas"
- **Tujuan:** Mengubah fokus "gengsi kampus" menjadi "kualitas pendidikan"

Representational Transformation (Safety)

- **Aksi:** mengubah kolom "Asal Universitas" menjadi "Kesesuaian kurikulum dengan jobdesk"
- **Tujuan:** Menghilangkan dependensi reputasi kampus yang tidak relevan

Dokumentasi melalui Privacy Card

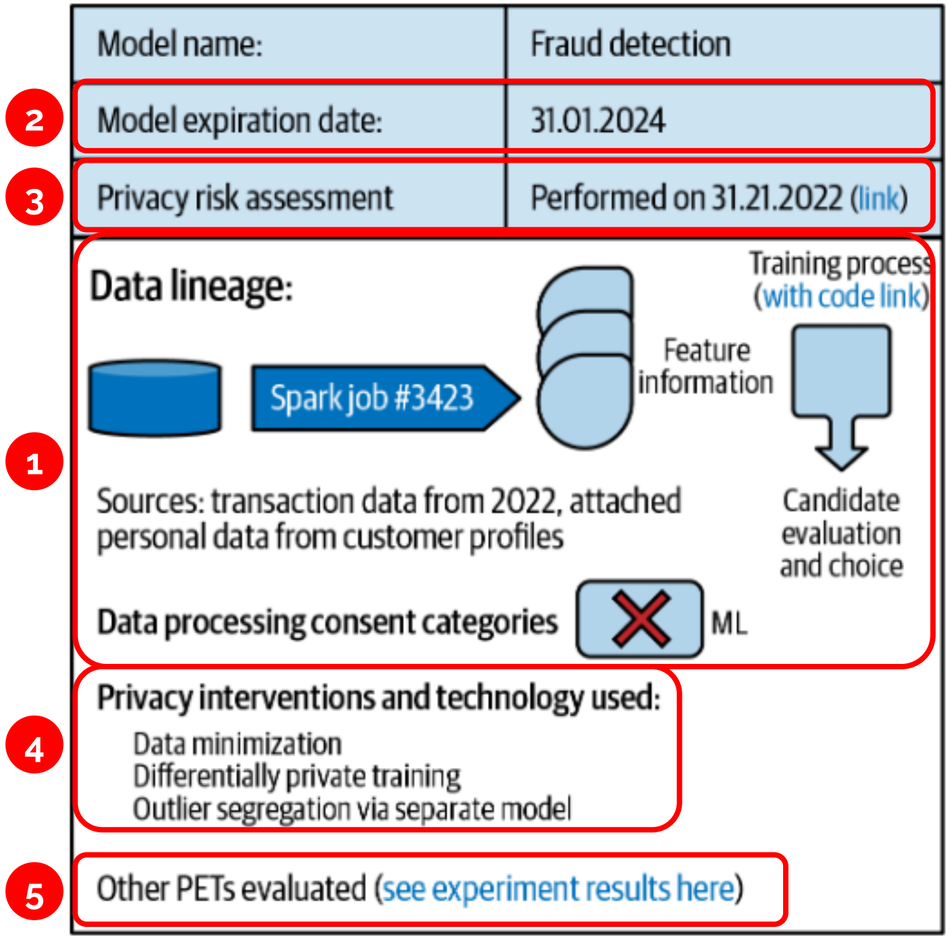

Terdiri dari beberapa komponen:

1) **Data lineage**

   Darimana data berasal, bagaimana kondisi ketika dikumpulkan dan persetujuan penggunaan data untuk keperluan apa saja

2) **Data retention and protection policies**

   Kebijakan apa yang digunakan (UU PDP, GDPR, dll), berapa lama data dapat digunakan tanpa anonimisasi

3) **Privacy risks**

   Resiko apa yang terjadi sebelum persiapan dan *training*, bagaimana cara evaluasinya, apakah ada analisis *outlier blindspot*

4) **Privacy techniques applied**

   Teknik privasi yang digunakan pada *preprocessing* dan *training*

5) **Approved usage**

   Rekomendasi metode atau kondisi model untuk digunakan

Review

- *Privacy-Aware Machine Learning* adalah cara untuk membangun model yang akurat tanpa harus mengorbankan data sensitif individu pada setiap tahapannya
- Beberapa tahapan mulai dari *Exploratory Data Analysis, Feature Engineering, Training Model,* hingga evaluasi model memiliki tekniknya masing-masing untuk menjaga data sensitif
- Harapannya Privacy-Aware ML bukan hanya menghilangkan informasi sensitif dari individu, namun juga menghilangkan diskriminasi sosial yang terdapat pada sebuah data

Tugas Studi Kasus: Toko Kelontong

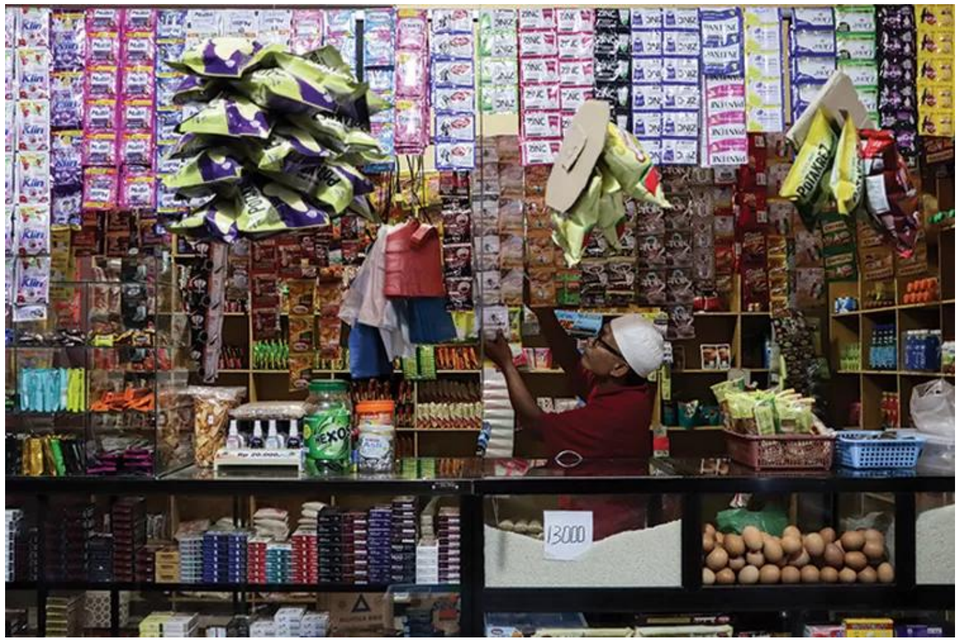

Joko adalah seorang pemilik warung kelontong kecil yang rajin dan jujur, namun ia tidak memiliki rekening bank (*unbanked*). Saat mengajukan pinjaman di sebuah aplikasi Fintech, AI secara otomatis menolak Joko karena ia tinggal di kecamatan dengan **tingkat gagal bayar tinggi** dan menggunakan *smartphone* murah. Secara historis, pola data tersebut dianggap "berisiko" oleh sistem, meskipun performa dagang Joko sangat baik.

Sebagai seorang Data Privacy Engineer, bagaimana seharusnya konsep *privacy-aware machine learning* dijalankan untuk mengatasi kasus ini? Jelaskan dengan 3 konsep Algorithmic Anonymization, Proxy Transformation, dan Representational Transformation.

Kerjakan secara individu, kumpulkan di MyITS Classroom maksimal ____ pukul ____

Supplement Materials

- **Privacy Preserving AI (Andrew Trask) | MIT Deep Learning Series**

https://www.youtube.com/watch?v=4zrU54VIK6k

- **Andrew Trask | Privacy preserving AI @ Vision Weekend USA 2025**

https://www.youtube.com/watch?v=BBthg7Czrd0

- **Privacy Preserving Machine Learning**

https://www.youtube.com/watch?v=griFrIBab6Q

Terima Kasih

Ada pertanyaan?